Sustentación APP

Primero, analizando los datos.

El dataset corresponde a mediciones de disponibilidad del sistema tomadas cada 5 minutos durante un periodo de aproximadamente 11 días, desde el 1 hasta el 11 de febrero de 2026. Cada registro contiene un timestamp y el número de tiendas disponibles en ese instante, lo que permite hacer un análisis temporal detallado del comportamiento del sistema.

El primer paso fue el procesamiento de los datos. Los archivos originales estaban en formato ancho, donde cada columna representaba un momento en el tiempo. Para poder analizarlos correctamente, se transformaron a formato largo, obteniendo dos variables principales: tiempo (timestamp) y disponibilidad. Además, se limpiaron valores inválidos y se convirtieron los datos a tipos numéricos y de fecha.

Una vez estructurados los datos, se realizó un análisis exploratorio. Se calcularon métricas básicas como promedio, valores mínimos y máximos, lo que permite tener una idea general del nivel de disponibilidad del sistema. Sin embargo, estas métricas no son suficientes para entender completamente el comportamiento.

Por esta razón, se incorporó el análisis de variabilidad, que es el elemento central del modelo. Se calcularon la desviación estándar, el rango y el coeficiente de variación. Este último permite medir qué tan inestable es el sistema en relación con su promedio. Con base en este valor, se clasificó el comportamiento en categorías como “muy estable”, “estable”, “inestable” y “muy inestable”.

Adicionalmente, se analizaron patrones temporales. Se identificó la hora del día con mayor variabilidad, lo que permite detectar momentos críticos en los que el sistema presenta mayor inestabilidad. También se detectaron caídas, definidas como disminuciones bruscas en la disponibilidad, utilizando un umbral basado en percentiles.

Con estos elementos, se construyó una capa de análisis que no solo describe los datos, sino que interpreta el comportamiento del sistema.

Finalmente, se integró un chatbot que permite consultar los datos en lenguaje natural. El sistema detecta fechas dentro de la pregunta, filtra los datos correspondientes a ese día y genera un análisis automático. El chatbot no solo muestra métricas, sino que explica el comportamiento del sistema, especialmente en términos de estabilidad y variabilidad.

En resumen, la aplicación permite pasar de datos crudos a interpretaciones claras, facilitando el entendimiento del comportamiento del sistema y la identificación de posibles problemas.

Mejoras futuras y escalabilidad.

Como mejora, el sistema podría incorporar modelos predictivos que permitan anticipar caídas o periodos de alta inestabilidad, utilizando técnicas de series de tiempo o aprendizaje automático. También se podría enriquecer el análisis incluyendo más variables, como tráfico, demanda o eventos externos, para entender mejor las causas de las fluctuaciones.

Otra mejora importante sería hacer el análisis más dinámico, permitiendo detectar automáticamente el peor día, las horas más críticas o tendencias a lo largo de semanas o meses, sin necesidad de que el usuario lo solicite explícitamente.

En términos de escalabilidad, el sistema podría adaptarse para procesar grandes volúmenes de datos en tiempo real mediante el uso de pipelines de datos y almacenamiento en bases de datos distribuidas. Además, el chatbot podría integrarse con sistemas empresariales o dashboards en producción, permitiendo a usuarios no técnicos interactuar con los datos de forma sencilla.

Finalmente, se podría desplegar como un servicio web, donde múltiples usuarios puedan consultar el estado del sistema simultáneamente, convirtiéndolo en una herramienta de monitoreo inteligente a nivel organizacional.

Plus:

Adicionalmente, en el archivo Jupyter Notebook se realizó un análisis exploratorio más profundo de los datos. Este análisis incluye la visualización de la serie temporal, distribuciones, detección de caídas, análisis por hora y por día, así como herramientas más avanzadas como autocorrelación y descomposición de la serie temporal.

Este tipo de análisis es fundamental si se desea avanzar hacia modelos de Machine Learning, ya que permite entender la estructura de los datos, identificar patrones, estacionalidades y comportamientos repetitivos en el tiempo. Por ejemplo, se observan ciclos claros en la disponibilidad del sistema y variaciones dependiendo de la hora del día, lo cual es clave para modelos predictivos.

Además, se exploraron técnicas como la media móvil (rolling mean) para identificar tendencias suavizadas y la descomposición de la serie en componentes de tendencia, estacionalidad y ruido, lo que facilita separar los diferentes factores que afectan el sistema.

En general, este análisis profundo permite preparar los datos de manera adecuada para futuros enfoques de Machine Learning, tanto predictivos como generativos, asegurando que los modelos aprendan patrones reales y no ruido.

Uso de IA:

Se utilizó inteligencia artificial como herramienta de apoyo durante el desarrollo. Principalmente, se empleó para corregir errores en el código y para consultar la implementación de métodos o funciones de librerías que no se recordaban con precisión.

Además, la IA fue útil para explorar alternativas a las soluciones planteadas inicialmente, permitiendo considerar distintos enfoques para el análisis y procesamiento de los datos. Esto facilitó la toma de decisiones más informadas y la mejora continua del diseño del sistema.